

**MODELAGEM HIERÁRQUICA PARA IDENTIFICAÇÃO
DE DISCURSOS OFENSIVOS:
Uma abordagem baseada em Processamento de Linguagem Natural**

***HIERARCHICAL MODELING FOR THE IDENTIFICATION
OF OFFENSIVE DISCOURSE:***

A Natural Language Processing Approach

Ellen Christine Ferreira Ozores (FATEC RUBENS LARA)
ellen.ozores@aluno.cps.sp.gov.br

Mel Yukari Tognoli Atsuji (FATEC RUBENS LARA)
mel.atsuji@aluno.cps.sp.gov.br

RESUMO

Este trabalho apresenta uma análise sobre a identificação automática de discursos ofensivos em textos publicados em ambientes digitais, utilizando técnicas de Processamento de Linguagem Natural (PLN) e aprendizado de máquina. O objetivo principal foi avaliar o desempenho de modelos de classificação textual na detecção de conteúdos ofensivos, considerando desafios como ambiguidades linguísticas, subjetividade e contexto semântico. Para isso, foram utilizados os datasets públicos *OLID (Offensive Language Identification Dataset)*, *Toxic Comment Classification Challenge* e *Davidson Hate Speech Dataset*. Os dados passaram por etapas de pré-processamento textual, padronização de rótulos e vetorização por meio da técnica TF-IDF. Em seguida, foram aplicados os algoritmos Regressão Logística, Naive Bayes e Random Forest, avaliados com métricas de acurácia, precisão, recall e F1-score. Os resultados demonstraram desempenho satisfatório dos modelos na identificação de conteúdos ofensivos, com destaque para a Regressão Logística, que apresentou maior equilíbrio entre as métricas analisadas. Além disso, observou-se relação significativa entre polaridade negativa e presença de linguagem ofensiva, reforçando o potencial das técnicas de PLN no apoio à moderação automática de conteúdo em plataformas digitais.

Palavras-chave: Processamento de Linguagem Natural; Discurso Ofensivo; Aprendizado de Máquina; Classificação Textual.

ABSTRACT

This study presents an analysis of the automatic identification of offensive discourse in texts published in digital environments using Natural Language Processing (NLP) and machine learning techniques. The main objective was to evaluate the performance of text classification models in detecting offensive content, considering challenges such as linguistic ambiguities, subjectivity, and semantic context. For this

purpose, the public datasets OLID (Offensive Language Identification Dataset), Toxic Comment Classification Challenge, and Davidson Hate Speech Dataset were used. The data underwent text preprocessing, label standardization, and vectorization using the TF-IDF technique. Subsequently, Logistic Regression, Naive Bayes, and Random Forest algorithms were applied and evaluated using accuracy, precision, recall, and F1-score metrics. The results demonstrated satisfactory performance of the models in identifying offensive content, with Logistic Regression showing the most balanced performance among the evaluated metrics. In addition, a significant relationship was observed between negative polarity and offensive language, reinforcing the potential of NLP techniques to support automatic content moderation on digital platforms.

KEYWORDS: *Natural Language Processing; Offensive Speech; Machine Learning; Text Classification.*

1 INTRODUÇÃO

O crescimento exponencial das redes sociais e das plataformas digitais tem ampliado significativamente o volume de interações online, possibilitando a rápida disseminação de informações em escala global. No entanto, esse cenário também favoreceu o aumento de conteúdos nocivos, como insultos, ameaças e discursos de ódio, que impactam diretamente a experiência e a segurança dos usuários (Schmidt; Wiegand, 2017). Segundo Wulczyn et al. (2017), uma parcela significativa das interações em plataformas digitais contém algum nível de toxicidade, com isso, esse cenário acaba evidenciando a relevância do problema e a necessidade de soluções eficazes para sua mitigação.

Diante do grande volume de dados gerados diariamente, a moderação manual torna-se limitada, tanto pela dificuldade de escalabilidade, quanto pela inconsistência entre avaliadores humanos. Nesse contexto, técnicas de Processamento de Linguagem Natural (PLN) e aprendizado de máquina têm sido amplamente empregadas para automatizar a detecção de conteúdos ofensivos, permitindo a análise em larga escala (Schmidt; Wiegand, 2017). Contudo, a identificação de discurso ofensivo permanece um desafio complexo, uma vez que depende de fatores contextuais e subjetivos, podendo variar de acordo com a interpretação dos anotadores e com características culturais e linguísticas (Zeeraak Waseem, 2016).

Além disso, conforme Thomas Davidson et al. (2017), a distinção entre diferentes tipos de linguagem ofensiva — como discurso de ódio, linguagem abusiva e conteúdo neutro — não é trivial, sendo frequentemente confundida tanto por humanos quanto por modelos automáticos. Nesse sentido, abordagens tradicionais baseadas em classificação binária mostram-se insuficientes para capturar a complexidade do fenômeno, alternativamente, modelos de classificação hierárquica permitem uma análise mais detalhada, considerando múltiplos níveis de informação, como a presença de ofensa, o tipo de ataque e o alvo da agressão (Marcos Zampieri et al., 2019).

Dessa forma, o presente trabalho tem como objetivo avaliar modelos de classificação hierárquica para a identificação de discurso ofensivo em textos online. Para isso, são utilizados diferentes conjuntos de dados — *OLID (Offensive Language Identification Dataset)*, *Toxic Comment Classification Challenge* e *Davidson Hate Speech Dataset* — permitindo a integração e padronização de categorias de toxicidade. A partir dessa abordagem, busca-se analisar as ambiguidades linguísticas presentes nos dados e seu impacto no desempenho de modelos de classificação automática.

2 FUNDAMENTAÇÃO TEÓRICA

O discurso ofensivo no ambiente digital tem se consolidado como uma preocupação crescente, especialmente diante da expansão das redes sociais e do aumento do volume de interações online. Segundo Franco (2024), a dinâmica do ciberespaço favorece a rápida circulação de conteúdos polêmicos e potencialmente nocivos, ampliando a exposição dos usuários a comportamentos agressivos e manifestações de violência verbal. Nesse cenário, plataformas digitais tornam-se ambientes propícios para a disseminação de insultos, ameaças e discursos discriminatórios, dificultando a manutenção de interações saudáveis e seguras.

Além do impacto na qualidade das interações digitais, a exposição contínua a conteúdos ofensivos pode gerar consequências relevantes para os usuários. Conforme apontado pela UNESCO (2023), discursos de ódio e violência verbal em ambientes online estão associados ao sofrimento psicológico, exclusão digital e

silenciamento de grupos historicamente vulnerabilizados, comprometendo sua participação em espaços públicos digitais.

2.1 Processamento de Linguagem Natural aplicado à classificação textual

O Processamento de Linguagem Natural (PLN) consiste em uma área que integra conhecimentos de ciência da computação, linguística e ciência da informação, com o objetivo de possibilitar que sistemas computacionais processem, interpretem e analisem linguagem humana de forma automatizada (Ladeira, 2010). Seu uso tem se expandido significativamente em tarefas relacionadas à classificação textual, análise de sentimentos, recuperação de informação e identificação de padrões linguísticos em grandes volumes de dados.

Segundo Fonseca et al. (2018), ferramentas de PLN possibilitam a extração, organização e categorização de informações textuais por meio de técnicas automatizadas, contribuindo para maior eficiência no tratamento de dados não estruturados. Essas abordagens tornam-se particularmente relevantes em cenários com elevada produção de conteúdo digital, nos quais a análise manual se torna inviável.

Além disso, métodos de similaridade textual e representação computacional de linguagem são frequentemente aplicados para otimizar a análise e comparação entre documentos, permitindo identificar relações semânticas e padrões relevantes em bases textuais (Forbici, 2024). Dessa forma, o PLN constitui uma base fundamental para sistemas de classificação automática, como aqueles aplicados à identificação de conteúdos ofensivos nos ambientes digitais.

2.2 Desafios na detecção automática de discurso ofensivo

A detecção automática de discurso ofensivo apresenta desafios significativos devido à complexidade linguística e contextual das interações em ambientes digitais. Diferentemente de tarefas tradicionais de classificação textual, quando falamos da detecção de comentários que são subjetivos, exige não apenas o reconhecimento de palavras agressivas, mas também a interpretação de contexto, intenção comunicativa, ironia e ambiguidades semânticas, fatores que dificultam a generalização de modelos computacionais (Guide, 2022). Além disso, segundo

Trajano (2023), a eficácia desses modelos depende diretamente da qualidade e diversidade dos conjuntos de dados utilizados no treinamento, tornando essencial a construção de bases textuais bem anotadas.

Outro desafio relevante refere-se aos vieses algorítmicos presentes nos sistemas automatizados. Conforme Silva (2022), modelos treinados em bases de dados enviesadas podem reproduzir padrões discriminatórios já existentes na sociedade, comprometendo a confiabilidade e a equidade dos sistemas de detecção.

No contexto de classificação textual, modelos supervisionados de aprendizado de máquina têm sido amplamente empregados para identificação automática de padrões linguísticos em grandes volumes de dados. Segundo Trajano (2023), técnicas de classificação aplicadas ao Processamento de Linguagem Natural permitem categorizar textos de forma automatizada a partir de dados previamente rotulados, sendo especialmente úteis em tarefas de detecção de linguagem tóxica e discurso ofensivo.

Entre os algoritmos frequentemente utilizados nesse tipo de aplicação, destacam-se a Regressão Logística, adequada para tarefas de classificação binária e multiclasse devido à sua simplicidade e interpretabilidade; o Naive Bayes, reconhecido por sua eficiência computacional em problemas de classificação textual baseados em frequência de termos; e o Random Forest, método baseado em múltiplas árvores de decisão que contribui para redução de overfitting e maior capacidade de generalização dos modelos (Trajano, 2023).

3 PROCEDIMENTOS METODOLÓGICOS

O presente trabalho caracteriza-se como uma pesquisa aplicada, de abordagem quantitativa e experimental, com foco na avaliação de modelos de classificação hierárquica para identificação automática de discurso ofensivo em mensagens online. Para a realização dos experimentos, foram utilizados três datasets públicos disponíveis na plataforma *Kaggle*: OLID (*Offensive Language Identification Dataset*), composto por mensagens do *Twitter/X* anotadas hierarquicamente quanto à presença, tipo e alvo de conteúdo ofensivo; *Toxic Comment Classification Challenge*, contendo comentários da *Wikipédia* classificados

em categorias como toxicidade, insulto, ameaça e discurso de ódio; e *Davidson Hate Speech Dataset*, formado por publicações do *Twitter* anotadas em classes de discurso de ódio, linguagem ofensiva e conteúdo neutro.

A implementação foi desenvolvida em linguagem Python, com apoio das bibliotecas Pandas, NLTK e Scikit-learn. Inicialmente, os datasets foram analisados individualmente e submetidos a etapas de pré-processamento textual, incluindo remoção de URLs, pontuações, caracteres especiais, números, conversão para letras minúsculas e remoção de stopwords.


Em razão das diferenças estruturais entre os datasets, realizou-se uma etapa de padronização dos rótulos, reorganizando categorias semanticamente equivalentes em uma estrutura hierárquica comum. Posteriormente, os textos foram convertidos para representação numérica por meio da técnica TF-IDF, permitindo seu uso em tarefas de classificação automática. Por fim, os dados foram divididos em conjuntos de treinamento e teste para avaliação dos modelos, utilizando métricas de desempenho como acurácia, precisão, recall e F1-score.

4 ANÁLISE DOS RESULTADOS

A presente seção apresenta os resultados obtidos a partir das análises de sentimento e da aplicação dos modelos de classificação textual sobre os datasets utilizados. Inicialmente, foram realizadas análises exploratórias relacionadas à polaridade e distribuição dos sentimentos presentes nos textos e em seguida, foram avaliados os modelos Regressão Logística, Naive Bayes e Random Forest por meio de métricas de classificação e matrizes de confusão.

A análise de sentimentos foi realizada com o objetivo de identificar padrões emocionais presentes nos textos utilizados nos datasets, permitindo observar a relação entre polaridade textual e presença de discurso ofensivo.

Figura 01 – Distribuição dos sentimentos identificados nos textos.




Fonte: Elaborado pelos autores.

A Figura 1 apresenta a distribuição dos sentimentos classificados como positivos, negativos e neutros. Observa-se predominância significativa de sentimentos negativos nos textos analisados, comportamento esperado considerando que os datasets utilizados possuem foco em comentários tóxicos, linguagem ofensiva e discurso de ódio, com isso, esse resultado demonstra coerência entre os dados utilizados e o objetivo da pesquisa, uma vez que conteúdos ofensivos tendem a apresentar maior carga emocional negativa. Ainda assim, também foram identificados textos classificados como neutros e positivos, evidenciando que nem toda mensagem considerada ofensiva apresenta polaridade extremamente negativa, especialmente em casos de ironia, sarcasmo ou ambiguidades linguísticas, dessa forma, a presença de diferentes polaridades reforça a complexidade do problema de classificação automática de discurso ofensivo, indicando que a toxicidade textual não depende exclusivamente do sentimento expresso, mas também do contexto semântico e da intenção comunicativa presente na mensagem.

Com o objetivo de aprofundar a análise exploratória, foi realizada a comparação entre os valores de polaridade textual e as classes ofensivas atribuídas aos comentários, como mostra a Figura 02.

Figura 02 – Distribuição da polaridade textual em relação às classes ofensivas.




Fonte: Elaborado pelos autores.

Com os resultados na Figura 2, observa-se que textos classificados como ofensivos apresentam tendência a polaridades mais negativas, enquanto conteúdos não ofensivos concentram-se em valores mais próximos da neutralidade ou positividade. Entretanto, também é possível observar sobreposição entre as distribuições das classes, indicando que determinados conteúdos ofensivos podem apresentar polaridade neutra ou até positiva, esse comportamento evidencia uma das principais dificuldades relacionadas à detecção automática de discurso ofensivo, já que mensagens potencialmente tóxicas podem depender fortemente do contexto e da interpretação semântica.

Dessa forma, o uso da análise de sentimentos reforçou a necessidade da utilização de técnicas de Processamento de Linguagem Natural capazes de identificar não apenas polaridade emocional, mas também padrões linguísticos mais complexos associados à toxicidade textual.

Após as etapas de pré-processamento e vetorização textual utilizando TF-IDF, foram treinados modelos para classificação automática dos conteúdos em ofensivos e não ofensivos, sendo avaliados por meio das métricas Accuracy, Precision, Recall e F1-score, além da análise qualitativa das matrizes de confusão, apresentados na Figura 3.

Figura 03 – Matrizes de confusão dos modelos Regressão Logística, Naive Bayes e Random Forest.



Fonte: Elaborado pelos autores.


Na Figura, observa-se que os três algoritmos apresentaram capacidade satisfatória de identificação de conteúdos ofensivos e não ofensivos, embora com diferenças na distribuição dos erros de classificação. A Regressão Logística alcançou um maior equilíbrio entre verdadeiros positivos e verdadeiros negativos, indicando estabilidade na separação entre as classes.

O modelo Naive Bayes foi satisfatório na identificação de padrões textuais, porém demonstrou maior incidência de classificações incorretas em determinados casos, especialmente em mensagens semanticamente ambíguas. Já o Random Forest apresentou um desempenho intermediário, conseguindo identificar padrões mais complexos por meio de múltiplas árvores de decisão, embora ainda apresentando limitações em alguns casos de sobreposição semântica entre as classes.

De forma geral, as matrizes evidenciam a dificuldade inerente ao problema de classificação de discurso ofensivo, principalmente devido à informalidade, subjetividade e ambiguidade presentes na linguagem utilizada em ambientes digitais.

Com o objetivo de comparar quantitativamente os algoritmos utilizados, a Figura 04 mostra os resultados da análise das métricas de desempenho obtidas por cada modelo.

Figura 04 – Comparação das métricas de desempenho entre os modelos.



Fonte: Elaborado pelos autores.

Ao analisar a Figura 4, é notório que a Regressão Logística apresentou desempenho mais equilibrado entre as métricas avaliadas, demonstrando elevada capacidade de generalização e eficiência na classificação textual baseada em TF-IDF, esse comportamento confirma sua ampla utilização em tarefas de Processamento de Linguagem Natural envolvendo classificação binária.

O modelo Naive Bayes apresentou desempenho competitivo, destacando-se principalmente pela simplicidade computacional e eficiência em tarefas baseadas em frequência de termos, entretanto, apresentou maior sensibilidade a determinadas distribuições textuais, o que impactou algumas métricas de desempenho.

O Random Forest chegou a resultados satisfatórios, especialmente na identificação de padrões mais complexos, porém com maior variação entre as métricas analisadas. Isso pode estar relacionado à alta dimensionalidade dos dados textuais vetorizados, característica que pode impactar modelos baseados em árvores de decisão.

De forma geral, os resultados demonstram que modelos lineares e probabilísticos continuam sendo altamente eficientes em tarefas de classificação textual baseadas em TF-IDF, especialmente em problemas relacionados à detecção automática de discurso ofensivo.

Diante disso, os resultados obtidos evidenciam que os modelos aplicados conseguiram identificar padrões relevantes relacionados à linguagem ofensiva nos datasets analisados, apresentando desempenho satisfatório na tarefa de classificação textual. As análises realizadas também permitiram observar a influência da polaridade emocional nos comentários, especialmente pela predominância de sentimentos negativos em conteúdos classificados como ofensivos.

Além disso, a comparação entre os algoritmos demonstrou diferenças no comportamento dos modelos diante de textos informais e semanticamente ambíguos, característica comum em interações digitais. Esses resultados indicam que técnicas de Processamento de Linguagem Natural associadas ao aprendizado de máquina possuem potencial significativo para auxiliar sistemas automáticos de moderação e identificação de discurso ofensivo em plataformas online.

5 CONSIDERAÇÕES FINAIS

O avanço das redes sociais e das plataformas digitais ampliou significativamente a circulação de conteúdos ofensivos e discursos de ódio no ambiente virtual, tornando a moderação manual cada vez mais difícil diante do grande volume de informações produzidas diariamente. Nesse contexto, técnicas de Processamento de Linguagem Natural e aprendizado de máquina vêm sendo amplamente utilizadas como alternativas para automatizar a identificação de conteúdos tóxicos e auxiliar sistemas de moderação em ambientes online.

Diante desse cenário, o presente trabalho teve como objetivo desenvolver e avaliar modelos de classificação textual aplicados à detecção automática de discurso ofensivo, utilizando os datasets OLID, Toxic Comment Classification Challenge e Davidson Hate Speech Dataset. Para isso, foram realizadas etapas de padronização dos dados, pré-processamento textual, tokenização e vetorização por meio da técnica TF-IDF, permitindo o treinamento dos modelos Regressão Logística, Naive Bayes e Random Forest.

Os resultados obtidos demonstraram que os algoritmos aplicados apresentaram desempenho satisfatório na identificação de conteúdos ofensivos,

evidenciando o potencial das técnicas de aprendizado supervisionado na classificação automática de textos. As análises também mostraram relação significativa entre polaridade negativa e presença de linguagem ofensiva, embora tenham sido identificados casos de ambiguidade semântica e subjetividade textual, fatores que representam desafios importantes para sistemas automáticos de detecção.

Além disso, a comparação entre os modelos permitiu observar diferenças no comportamento dos algoritmos diante de textos informais e semanticamente complexos, reforçando a importância da escolha adequada das técnicas utilizadas em tarefas de classificação textual. Entre os modelos avaliados, destacou-se o bom desempenho de abordagens amplamente utilizadas em Processamento de Linguagem Natural baseadas em representação vetorial de texto.

De forma geral, os resultados reforçam a relevância do uso de técnicas de Processamento de Linguagem Natural no desenvolvimento de ferramentas capazes de auxiliar a moderação de conteúdo em plataformas digitais, contribuindo para a redução da propagação de discursos ofensivos em ambientes online. Como trabalhos futuros, sugere-se a utilização de modelos mais avançados de aprendizado profundo, como arquiteturas baseadas em transformers, além da ampliação dos datasets utilizados e da inclusão de análises contextuais capazes de lidar com ironia, sarcasmo e ambiguidades linguísticas com maior precisão.

REFERÊNCIAS

DAVIDSON, Thomas et al. Automated hate speech detection and the problem of offensive language. Proceedings of the 11th International AAAI Conference on Web and Social Media (ICWSM), Montreal, p. 512–515, 2017. Disponível em: <https://ojs.aaai.org/index.php/ICWSM/article/view/14955>. Acesso em: 18 abr. 2026.

FONSECA, Alessandra Castilho da et al. AnoTex: um anotador textual para filtragem de dados em artigos científicos. Texto Livre: Linguagem e Tecnologia, Belo Horizonte, v. 11, n. 3, p. 40–64, set./dez. 2018. Disponível em: <http://periodicos.letras.ufmg.br/index.php/textolivres/article/view/13952>. Acesso em: 18 abr. 2026.

FORBICI, Guilherme. Aplicação de técnicas de processamento de linguagem natural para identificação de duplicidades em demandas de compras públicas. 2024.

Dissertação (Mestrado) – Universidade Federal de Santa Catarina, Florianópolis, 2024. Disponível em: <https://repositorio.ufsc.br/handle/123456789/264137>. Acesso em: 18 abr. 2026.

FRANCO, Ana Paula Cordeiro Lacerda. O discurso polêmico em postagens da revista VEJA no Instagram como propulsor da violência verbal em cibercomentários. 2024. Dissertação (Mestrado em Estudos Linguísticos) – Faculdade de Letras, Universidade Federal de Minas Gerais, Belo Horizonte, 2024. Disponível em: <https://repositorio.ufmg.br/>. Acesso em: 18 abr. 2026.

GUIDE, Bruno Ferrari. Detecção automática de discurso de ódio punitivista em redes sociais. 2022. Tese (Doutorado em Semiótica e Linguística Geral) – Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo, São Paulo, 2022. Disponível em: <https://www.teses.usp.br/teses/disponiveis/8/8139/tde-08122022-174035/>. Acesso em: 18 abr. 2026.

JIGSAW. Toxic Comment Classification Challenge. Kaggle, 2018. Disponível em: <https://www.kaggle.com/competitions/jigsaw-toxic-comment-classification-challenge>. Acesso em: 18 abr. 2026.

LADEIRA, Ana Paula. Processamento de linguagem natural: caracterização da produção científica dos pesquisadores brasileiros. 2010. 259 f. Tese (Doutorado em Ciência da Informação) – Escola de Ciência da Informação, Universidade Federal de Minas Gerais, Belo Horizonte, 2010. Disponível em: <http://hdl.handle.net/1843/ECID-8HKN29>. Acesso em: 18 abr. 2026.

SCHMIDT, Anna; WIEGAND, Michael. A survey on hate speech detection using natural language processing. Proceedings of the Fifth International Workshop on Natural Language Processing for Social Media, Valencia, p. 1–10, 2017. Disponível em: <https://aclanthology.org/W17-1101/>. Acesso em: 18 abr. 2026.

SILVA, Tarcízio. Racismo algorítmico: inteligência artificial e discriminação nas redes digitais. São Paulo: Edições Sesc São Paulo, 2022. Disponível em: <https://desvelar.org/wp-content/uploads/2023/09/racismo-algoritmico-politicas-publicas.pdf>. Acesso em: 18 abr. 2026.

TRAJANO, Douglas de Oliveira. Detecção de linguagem tóxica aplicada a textos em português. 2023. Dissertação (Mestrado em Ciência da Computação) – Escola Politécnica, Pontifícia Universidade Católica do Rio Grande do Sul, Porto Alegre, 2023. Disponível em: <https://repositorio.pucrs.br/dspace/handle/10923/25138>. Acesso em: 18 abr. 2026.

UNESCO. Countering online hate speech. Paris: UNESCO, 2015. Disponível em: <https://www.unesco.org/en/articles/countering-online-hate-speech>. Acesso em: 18 abr. 2026.

WASEEM, Zeerak. Are you a racist or am I seeing things? Annotator influence on hate speech detection. Proceedings of the First Workshop on NLP and Computational Social Science, Austin, p. 138–142, 2016. Disponível em: <https://aclanthology.org/W16-5618/>. Acesso em: 18 abr. 2026.

WULCZYN, Ellery et al. Ex Machina: Personal attacks seen at scale. Proceedings of the 26th International World Wide Web Conference (WWW 2017), Perth, p. 1391–1399, 2017. Disponível em: <https://dl.acm.org/doi/10.1145/3038912.3052591>. Acesso em: 18 abr. 2026.

ZAMPIERI, Marcos et al. Predicting the type and target of offensive posts in social media. In: NAACL-HLT 2019. Minneapolis: Association for Computational Linguistics, 2019. p. 1415–1420. Disponível em: <https://aclanthology.org/N19-1144/>.

ZAMPIERI, Marcos et al. Predicting the type and target of offensive posts in social media. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT), Minneapolis, p. 1415–1420, 2019. Disponível em: <https://aclanthology.org/N19-1144/>. Acesso em: 18 abr. 2026.